

MÉTODO BM25 – BEST MATCHING 25

BM25

Es considerado el estándar de la industria para la recuperación de información (Keyword Search) y es el sucesor directo del TF-IDF.

Ventajas de BM25 sobre TF-IDF. Ambos métodos miden la importancia de las palabras, BM25 corrige dos limitaciones críticas del TF-IDF tradicional:

- **Saturación del TF (Term Frequency)**: En TF-IDF, si una palabra aparece 100 veces, tiene 10 veces más importancia que si aparece 10 veces. BM25 aplica una "saturación": a partir de cierto número de apariciones, la importancia deja de crecer linealmente. Si ya viste la palabra 10 veces, verla 20 no duplica la relevancia.
- **Normalización por Longitud del Documento**: TF-IDF suele beneficiar injustamente a los documentos largos (porque tienen más palabras y mayor probabilidad de repetir términos). BM25 penaliza los documentos excesivamente largos y premia a los cortos que logran ser relevantes, asumiendo que un documento corto que menciona el término es más "específico".

¿CÓMO SE CALCULA?

$$IDF * \frac{TF * (k_1 + 1)}{TF + k_1 * (1 - b + b * (\frac{\text{document length}}{\text{average document length}}))}$$

IDF: frecuencia de documento inverso
TF: Frecuencia de termino
K1: Saturación. Controla qué tan rápido se satura el TF (usualmente entre 1.2 y 2.0).
b: (Penalización por longitud): Controla cuánto castigamos la longitud. Si b=1, la penalización es máxima; si b=0, se ignora la longitud (usualmente 0.75).

EJEMPLO

```
documents = [
    # Doc1: Corto y muy relevante (contiene "algoritmo" 1 vez en 4 palabras)
    "algoritmo de machine learning",

    # Doc2: Muy largo con "algoritmo" repetido muchas veces (spam/ruido)
    "algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo " +
    "el algoritmo es importante para algoritmo machine learning algoritmo algoritmo data science algoritmo " +
    "algoritmo deep learning algoritmo neural networks algoritmo python algoritmo java algoritmo algoritmo " +
    "algoritmo tensorflow algoritmo pytorch algoritmo scikit-learn algoritmo sklearn algoritmo kaggle algoritmo",

    # Doc3: Mediano y moderadamente relevante
    "introducción a algoritmo de optimización algoritmo genético algoritmo búsqueda",

    # Doc4: Sin el término
    "machine learning data science python programming"
]
```

Utilizar el archivo **utils.py** que está en el aula para crear script que realice un scoring para los documentos utilizando los dos métodos vistos en clase.

RESULTADOS

```
Documentos ordenados por relevancia (TF-IDF):
Documento 2: TF-IDF = 0.1689 - 'algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo el algoritmo es importante para algoritmo machine learning algoritmo
 algoritmo data science algoritmo algoritmo deep learning algoritmo neural networks algoritmo python algoritmo java algoritmo algoritmo algoritmo tensorflow algoritmo pytorch algoritmo scikit-learn al
goritmo sklearn algoritmo kaggle algoritmo'
Documento 3: TF-IDF = 0.0959 - 'introducción a algoritmo de optimización algoritmo genético algoritmo búsqueda'
Documento 1: TF-IDF = 0.0719 - 'algoritmo de machine learning'
Documento 4: TF-IDF = 0.0000 - 'machine learning data science python programming'

Documentos ordenados por relevancia (BM25):
Documento 1: BM25 = 0.0351 - 'algoritmo de machine learning'
Documento 3: BM25 = 0.0221 - 'introducción a algoritmo de optimización algoritmo genético algoritmo búsqueda'
Documento 2: BM25 = 0.0080 - 'algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo el algoritmo es importante para algoritmo machine learning algoritmo a
lgoritmo data science algoritmo algoritmo deep learning algoritmo neural networks algoritmo python algoritmo java algoritmo algoritmo algoritmo tensorflow algoritmo pytorch algoritmo scikit-learn algo
ritmo sklearn algoritmo kaggle algoritmo'
Documento 4: BM25 = 0.0000 - 'machine learning data science python programming'
```

Aspecto	TF-IDF	BM25
Saturación	La frecuencia crece sin límite	Satura (no sigue creciendo linealmente)
Docs largos	Pueden obtener altas puntuaciones	Penaliza documentos muy largos
Normalización	No normaliza por longitud	Normaliza por longitud promedio

RESULTADOS

```
Documentos ordenados por relevancia (TF-IDF):
Documento 2: TF-IDF = 0.1689 - 'algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo el algoritmo es importante para algoritmo machine learning algoritmo
 algoritmo data science algoritmo algoritmo deep learning algoritmo neural networks algoritmo python algoritmo java algoritmo algoritmo algoritmo tensorflow algoritmo pytorch algoritmo scikit-learn al
goritmo sklearn algoritmo kaggle algoritmo'
Documento 3: TF-IDF = 0.0959 - 'introducción a algoritmo de optimización algoritmo genético algoritmo búsqueda'
Documento 1: TF-IDF = 0.0719 - 'algoritmo de machine learning'
Documento 4: TF-IDF = 0.0000 - 'machine learning data science python programming'

Documentos ordenados por relevancia (BM25):
Documento 1: BM25 = 0.0351 - 'algoritmo de machine learning'
Documento 3: BM25 = 0.0221 - 'introducción a algoritmo de optimización algoritmo genético algoritmo búsqueda'
Documento 2: BM25 = 0.0080 - 'algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo algoritmo el algoritmo es importante para algoritmo machine learning algoritmo a
lgoritmo data science algoritmo algoritmo deep learning algoritmo neural networks algoritmo python algoritmo java algoritmo algoritmo algoritmo tensorflow algoritmo pytorch algoritmo scikit-learn algo
ritmo sklearn algoritmo kaggle algoritmo'
Documento 4: BM25 = 0.0000 - 'machine learning data science python programming'
```

Conclusión

- **TF-IDF** ranking muchas veces: Doc2 arriba (solo por repeticiones)
- **BM25** ranking: Doc1 arriba (es más relevante y conciso)
- BM25 es superior porque reconoce que repeticiones excesivas no significan relevancia.