🌏Ejecución de LLMs con Ollama

Created	@10 de marzo de 2026 11:41
Module Code	56BA1A Desarrollo de aplicaciones con IA





¿Por qué ejecutar modelos de forma local?

Hasta ahora, hemos usado la API de Gemini (Google). Sin embargo, trabajar de forma local ofrece ventajas estratégicas:

- **Privacidad y Seguridad:** Los datos nunca salen de tu computadora. Ideal para manejar información sensible o empresarial.
- **Costo Cero ($0):** No pagas por token ni por suscripción. El único límite es la capacidad de tu hardware.
- **Sin Dependencia de Internet:** Puedes desarrollar y ejecutar tus aplicaciones en entornos offline.
- **Personalización Total:** Tienes control sobre los parámetros del sistema y puedes probar modelos experimentales que no están en las nubes comerciales.

¿Qué es Ollama?

Ollama es una herramienta de código abierto que permite ejecutar modelos de lenguaje grandes (LLMs) de forma sencilla en macOS, Linux y Windows.

- **Función:** Gestiona la descarga, configuración y ejecución de modelos como Llama 3, Mistral o Phi-3.
- **Simplicidad:** Convierte tu computadora en un "servidor de inferencia" local al que puedes hacerle peticiones de la misma forma que a Gemini o OpenAI.

Descarga

Ollama

Ollama is the easiest way to automate your work using open models, while keeping your data safe.

https://ollama.com/



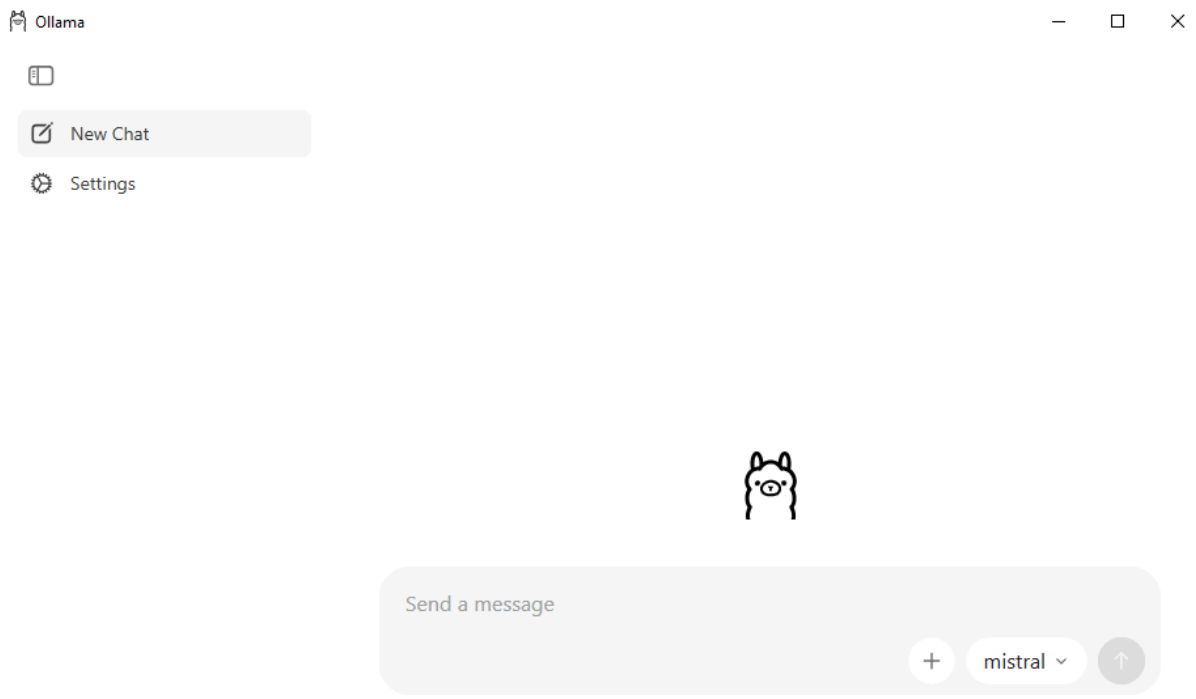
Download Ollama on macOS

Download Ollama for macOS

https://ollama.com/download



Aplicación



Integración con Python

Para conectar Ollama con tus scripts de Python (como lo hacías con Gemini), utilizaremos la librería oficial de Ollama.

```
pip install ollama
```

```
import ollama

# Configuración del modelo y el mensaje
# Aquí aplicamos lo aprendido hoy sobre Ingeniería de Promp
ts
def generate_local_response():
    system_prompt = """
    Eres un asistente técnico experto en inteligencia artif
icial.
    Tus respuestas deben ser concisas, en formato Markdown
y
    siempre debes incluir un ejemplo de código si es posibl
e.
    """
```

```
    user_prompt = "¿Cómo puedo crear un agente simple en Py
thon?"

    try:
        # Interacción con el modelo local Llama 3
        # Nota: El modelo debe haber sido descargado previa
mente con 'ollama pull llama3'
        response = ollama.chat(model='phi3', messages=[
            {
                'role': 'system',
                'content': system_prompt,
            },
            {
                'role': 'user',
                'content': user_prompt,
            },
        ])

        # Extraer y mostrar la respuesta
        print("--- RESPUESTA DEL MODELO LOCAL ---")
        print(response['message']['content'])

    except Exception as e:
        print(f"Error al conectar con Ollama: {e}")
        print("Asegúrate de que la aplicación Ollama esté a
bierta y el modelo descargado.")

if __name__ == "__main__":
    generate_local_response()
```