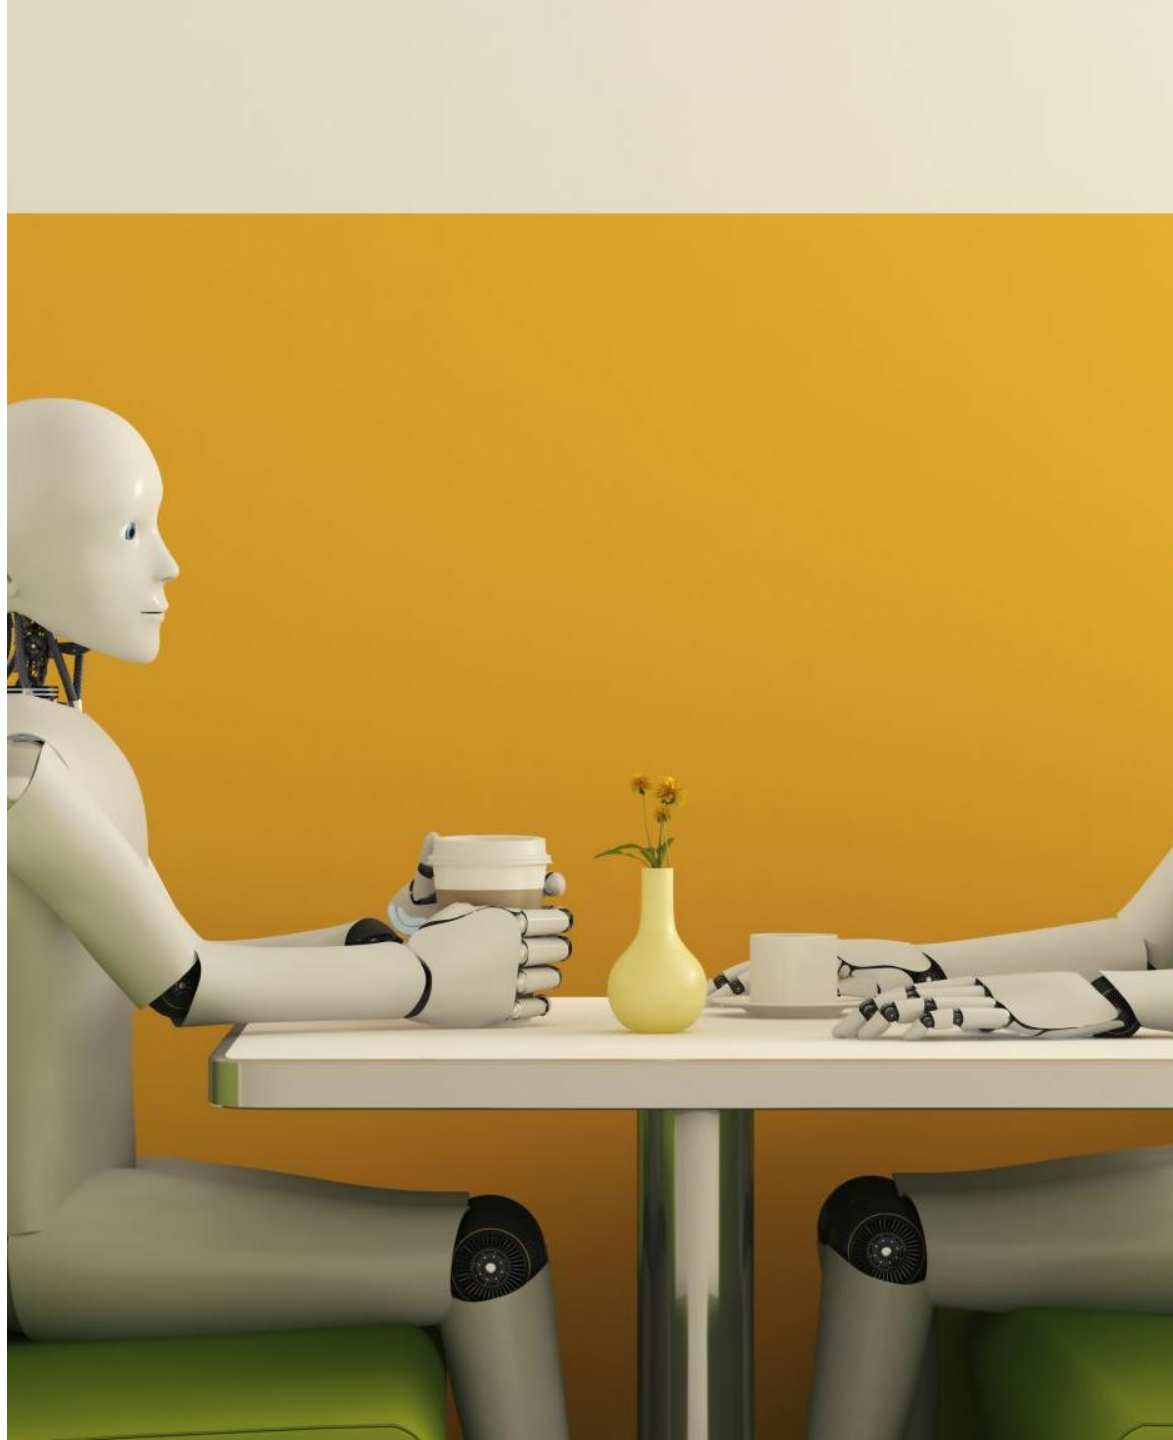
Introducción a RAG

Leandro Pájaro Fuentes

Contenido

- Introducción a RAG
- Arquitectura
- Introducción a los LLMs
- Retrieval

Introducción



RAG – **R**etrieval **A**ugmented **G**eneration

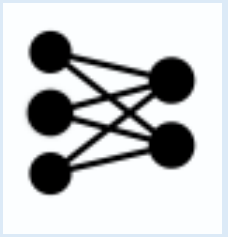
LLMS responden bien para

Resumir texto

Escribir texto

Generar código

RAG potencia al LLM



LLM

+



Nueva información

RAG – **R**etrieval **A**ugmented **G**eneration

¿por qué los hoteles son costosos los fines de semana?

Los hoteles suelen ser más costosos los fines de semana principalmente por oferta y demanda, pero hay varios factores interesantes detrás:

- Mayor demanda de ocio.
- Entre semana, muchos huéspedes viajan por trabajo.
- El fin de semana aumenta la demanda de turismo escapadas cortas eventos sociales (bodas, conciertos).

Eso hace que haya más personas buscando habitaciones al mismo tiempo, lo que eleva los precios.

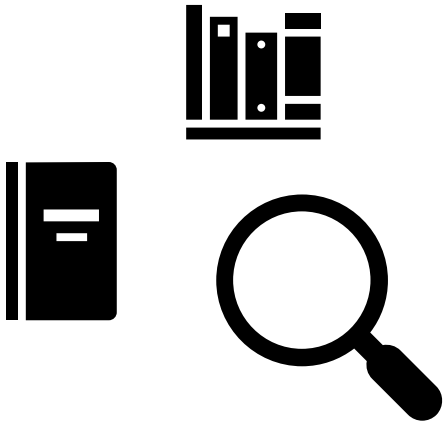
RAG – **R**etrieval **A**ugmented **G**eneration

¿por qué los hoteles son tan costosos este fin de semana en Cartagena?

Google →  → **Festival Internacional de Música**

RAG – **R**etrieval **A**ugmented **G**eneration

¿Por qué no se construyen mas hoteles en el centro de Cartagena?



Es necesario realizar una búsqueda extendida

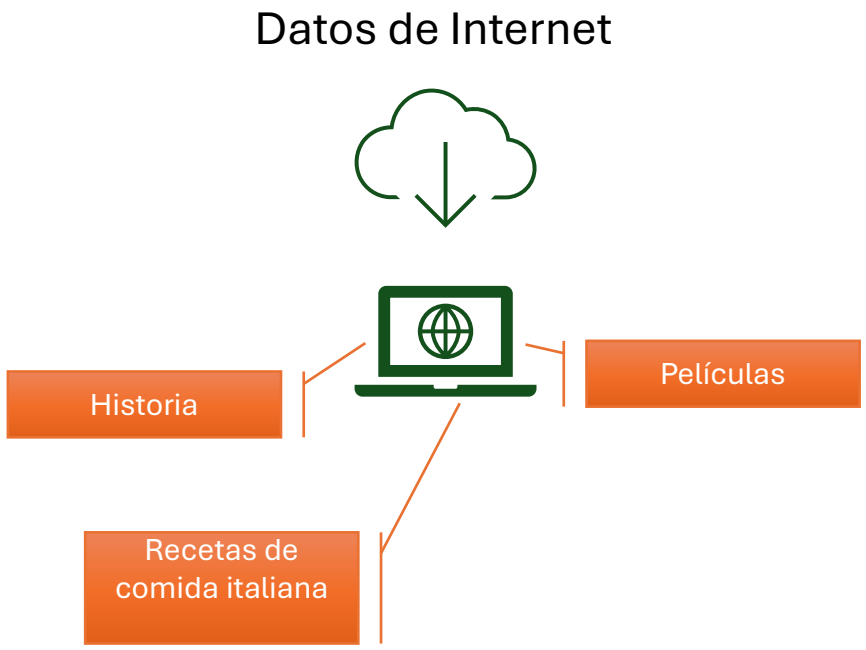
RAG – **R**etrieval **A**ugmented **G**eneration

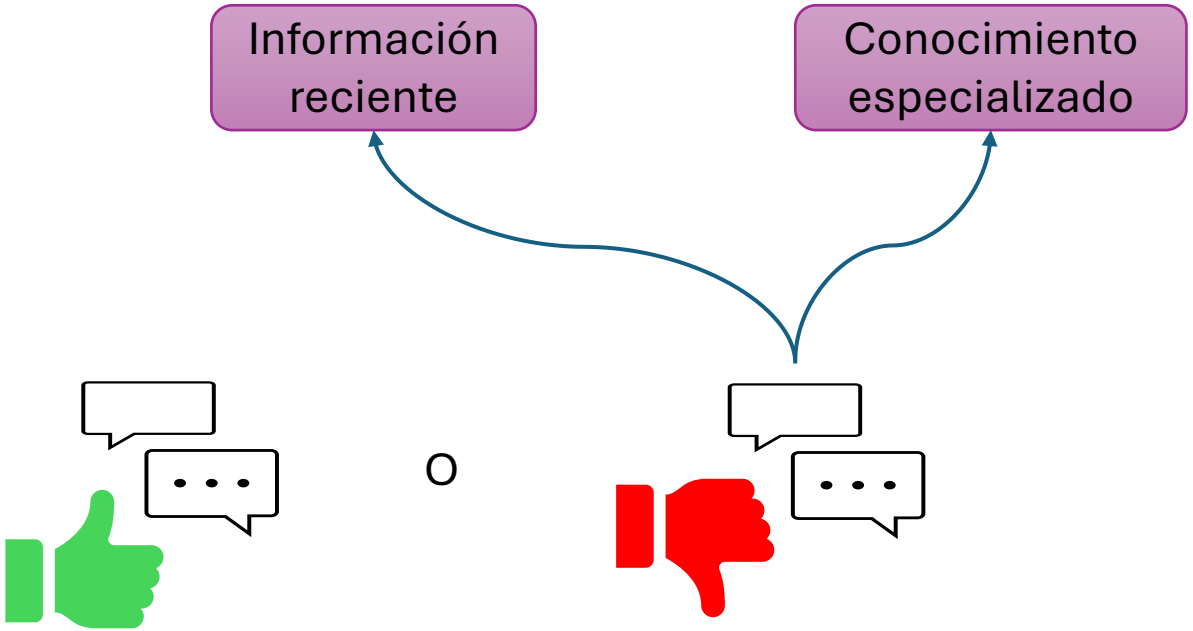
2 pasos para responder

	Recuperación	Generación
	Recolectar información →	**Razonar y responder**
¿Por qué los hoteles son costosos los fines de semana?	No es necesario recolectar información	Responder basado en el conocimiento
¿Por qué no se construyen mas hoteles en el centro de Cartagena?	Investigación en fuentes externas	Consolidar información, analizar y responder

RAG – **R**etrieval **A**ugmented **G**eneration

Comportamiento tradicional de un LLM





RAG – **R**etrieval **A**ugmented **G**eneration

Los LLMs no tienen información de

Bases de datos privadas

LLMs no pueden acceder a información confidencial.

Información restringida en Internet

Mucha información no está pública en Internet.

Datos en tiempo real

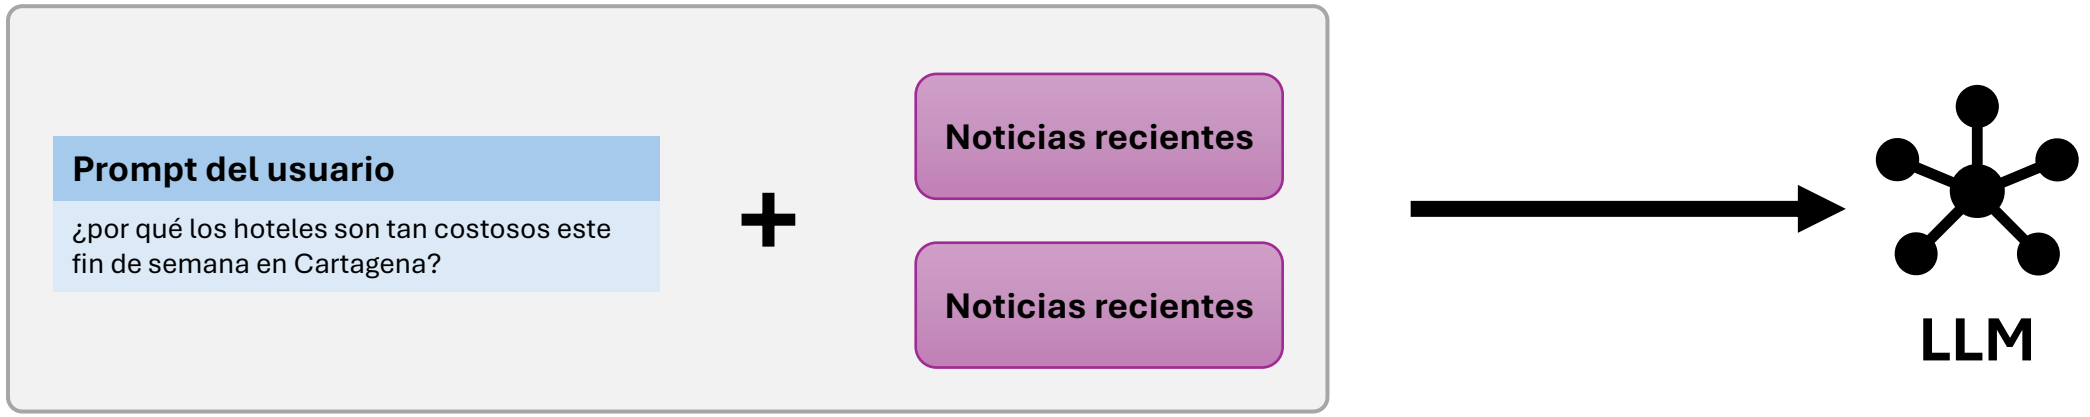
Información generada recientemente o falta de actualización en la data con la que fueron entrenados.

Arquitectura



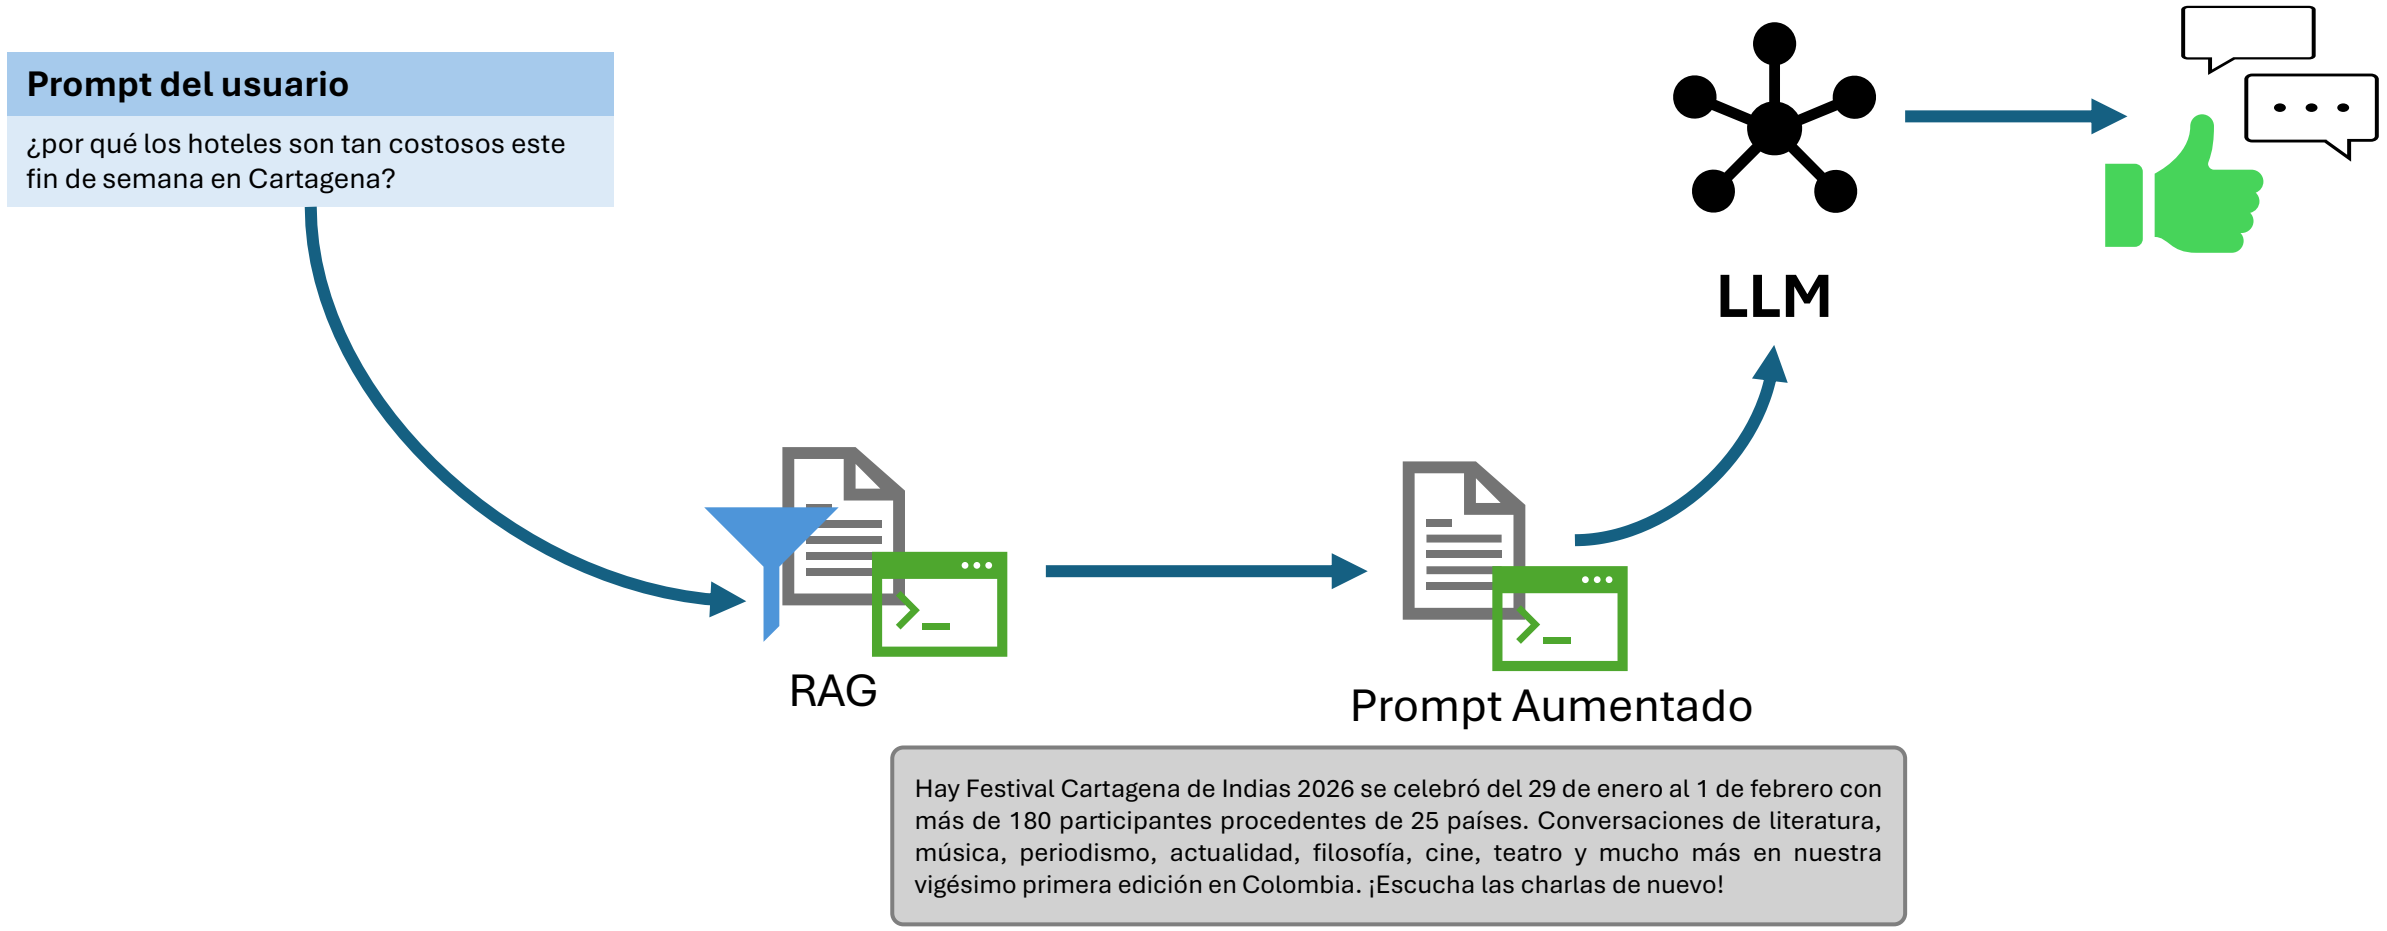
RAG – **R**etrieval **A**ugmented **G**eneration

Colocar información que no tiene el LLM en el Prompt



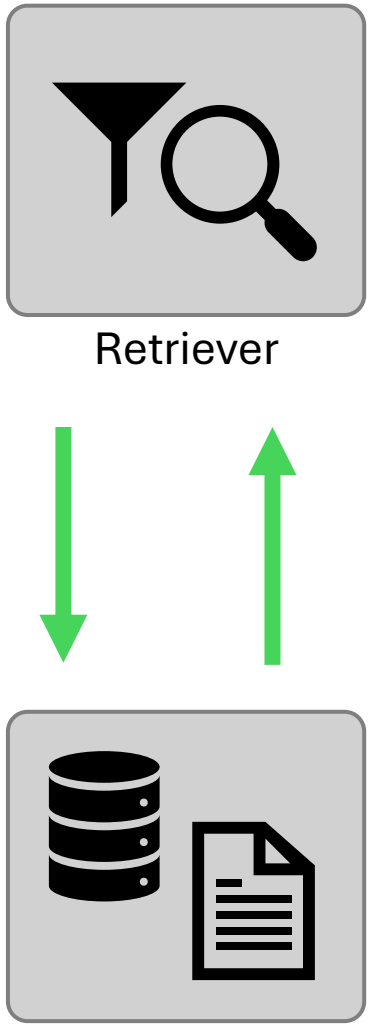
RAG – **R**etrieval **A**ugmented **G**eneration

Colocar información que no tiene el LLM en el Prompt



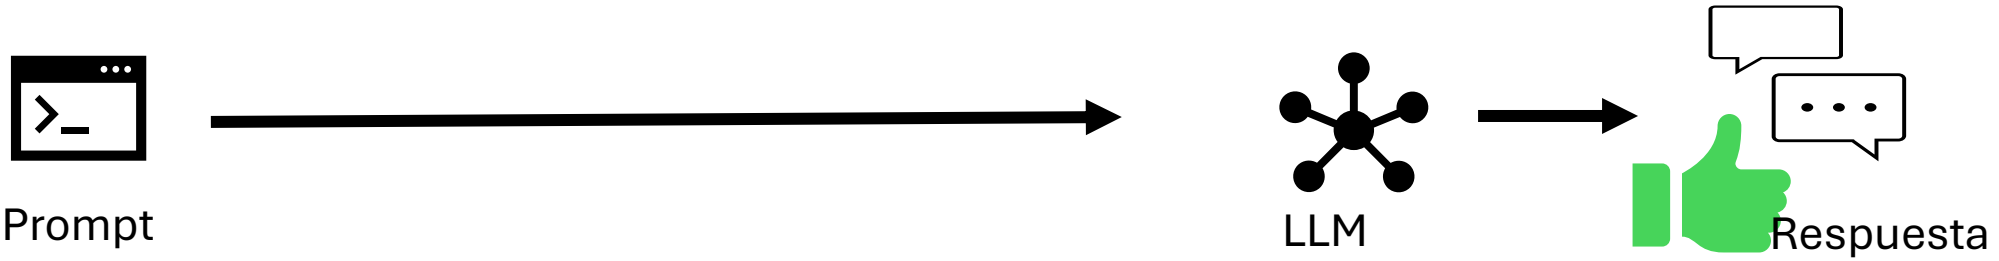
Retriever

- ✓ Gestiona la base de conocimientos de información confiable
- ✓ Recupera la información mas relevante que esté relacionada con el prompt y la comparte al LLM
- ✓ Mejora la generación de contenido

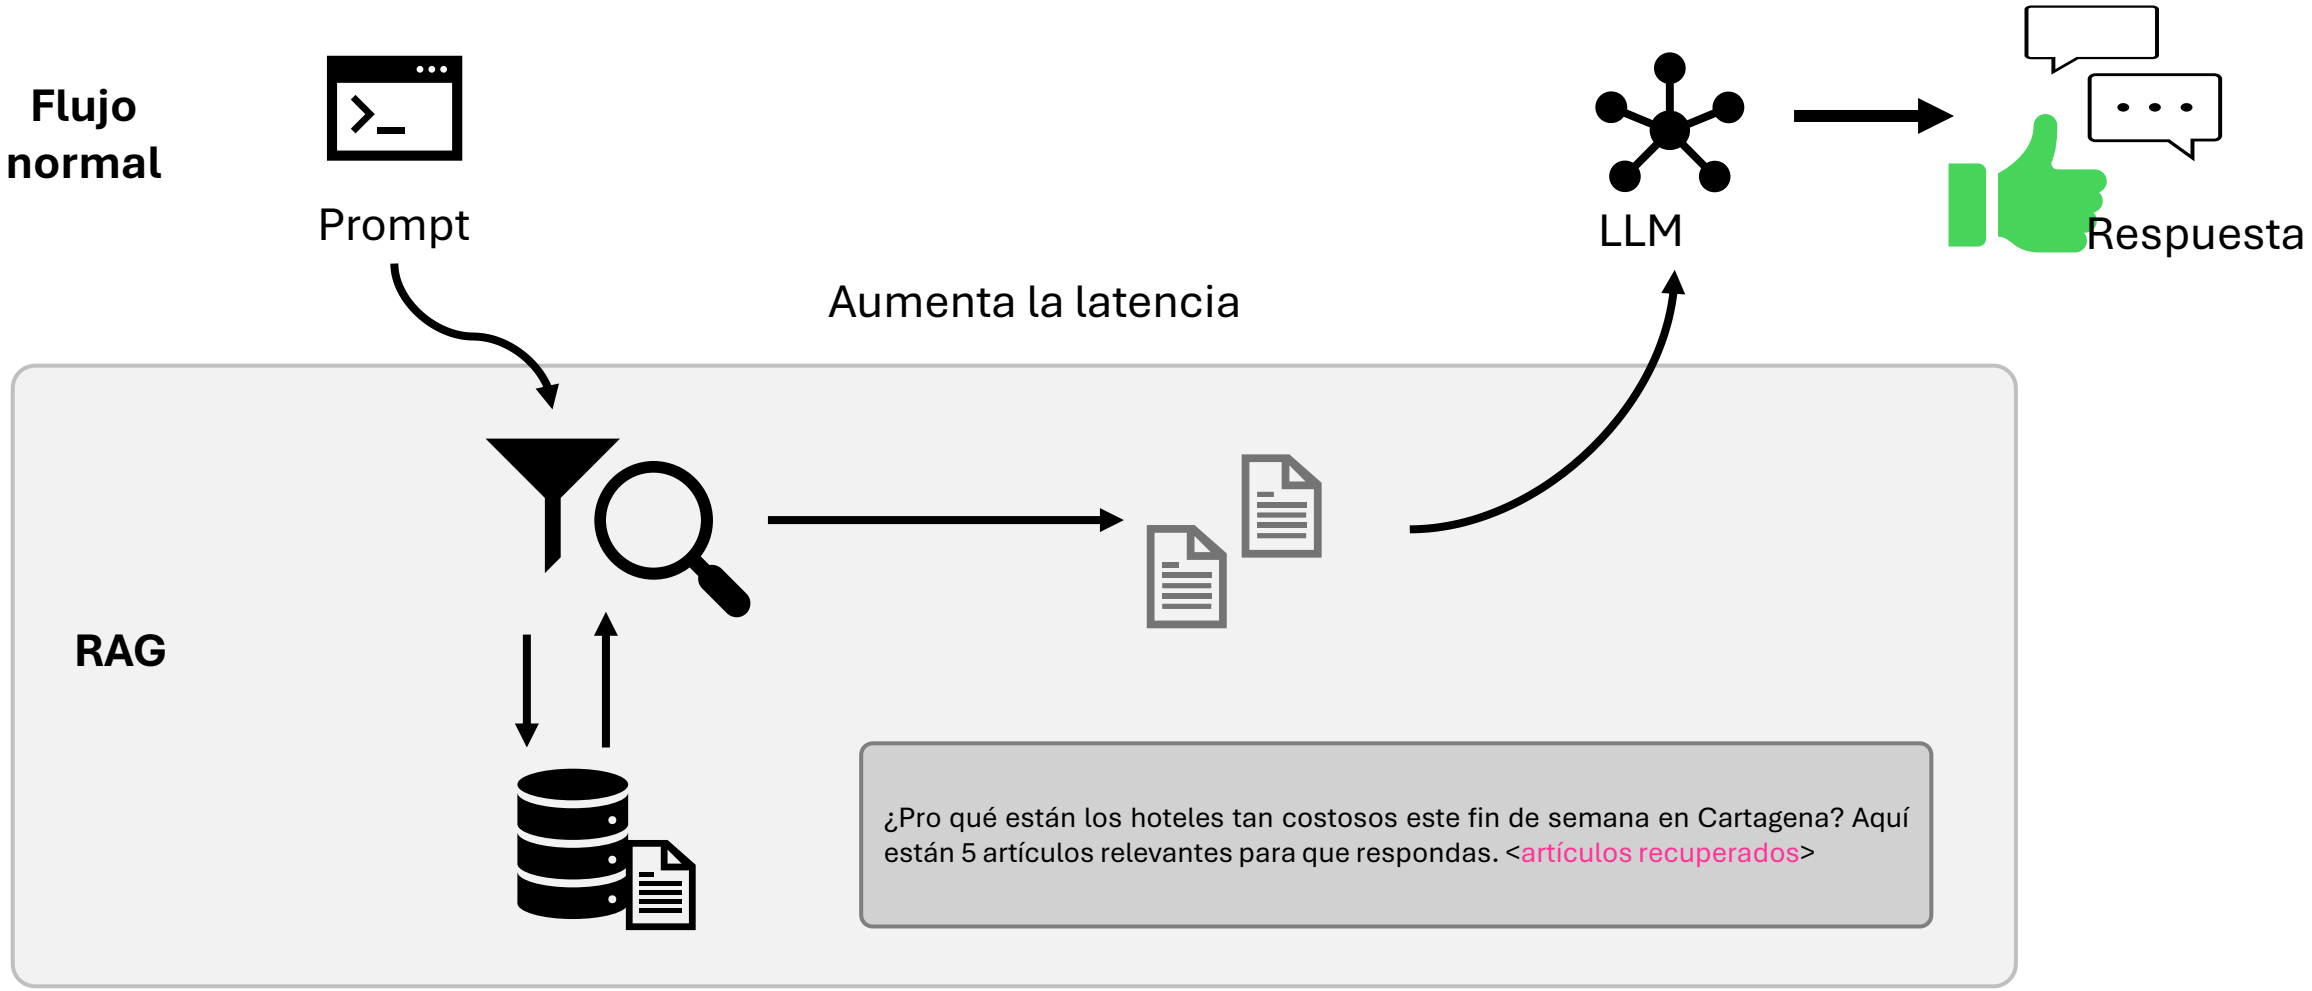


Detalle arquitectura

Flujo normal



Detalle arquitectura



Ventajas de implementar RAG



Introducción a los LLMs

Los LLM son solo un autocompletado sofisticado.

What a beautiful day, the sun is

Prompt

What a beautiful day, the sun is shining

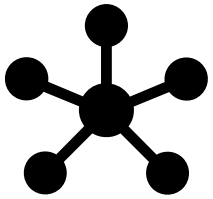
What a beautiful day, the sun is rising

What a beautiful day, the sun is out

Posibles opciones

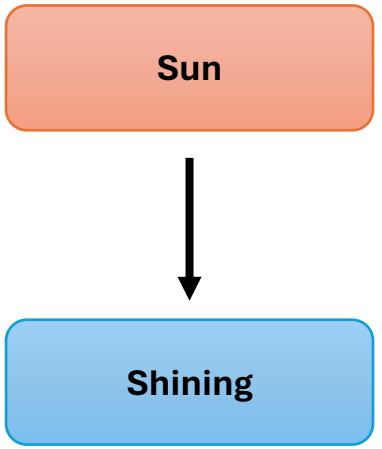
Los LLM son solo un autocompletado sofisticado.

What a beautiful day, the sun is exploding



Red Neuronal

- Modelo matemático complejo de lenguaje
- Almacena las palabras que aparecen junas frecuentemente y el orden en el cual pueden tener un contexto con significado
- LLMs usa este modelo para generar texto



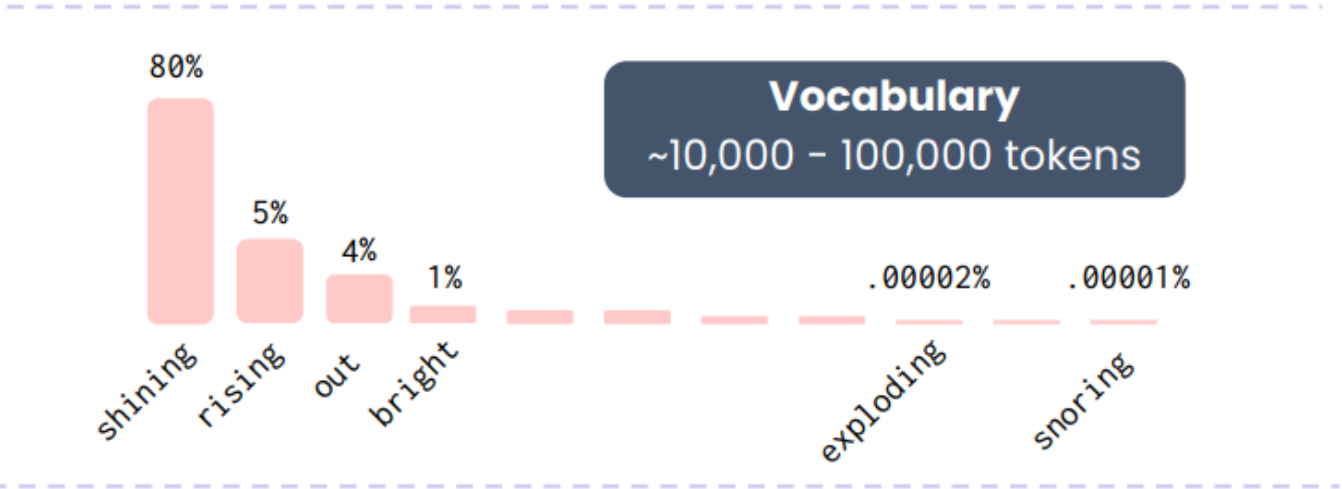
Funcionamiento de los LLMs

What a beautiful day, the sun is

Procesa el estado actual

Calcula las probabilidades

Selecciona el próximo token



shining

¿Por qué los LLMs alucinan?

- Los LLMs generan secuencias probables de palabras
  - Generan patrones estadísticos a partir de los datos con los cuales fueron entrenados.
- Brechas en la base de conocimientos producen respuestas imprecisas
  - Respuestas pueden “sonar correctas” pero no son ciertas.
- Verdadero <> probable
  - LLMs están diseñados para generar “probable” texto, no texto verdadero

¿Por qué los LLMs alucinan?

- Ejemplo

Si le preguntamos al modelo

¿Qué dice el artículo de María Kamila Amaya y Marlon Gómez sobre el uso de Llama 3 en startups de Noruega?

Lo que podría responder

El artículo de Amaya y Gomez (2025) concluye que el modelo **Llama 3 de Meta** es la herramienta preferida por startups noruegas debido a su eficiencia en procesos de logística, logrando una reducción del 20% en costos operativos.

Lo que realmente dice el artículo

El artículo no menciona a Llama 3; en realidad, los modelos utilizados fueron ChatGPT, GPT-3.5 y GPT-4.El estudio no habla de "costos de logística", sino de cómo el Prompt Engineering ayuda a startups en etapas tempranas a tomar mejores decisiones en general.



La IA elige palabras basándose en patrones. Si la IA ha leído mucho sobre "startups en Noruega" y sobre "Llama 3" por separado, su "cerebro" matemático puede mezclar ambos conceptos para crear una respuesta que **tenga sentido gramatical**, aunque no sea **verídica**.

RAG resuelve el problema de las alucinaciones



¿Por qué no agregar siempre en el prompt las fuentes?

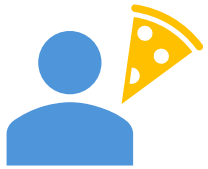
Alto costo de computo

- Prompts grandes consumen mas recursos computacionales para procesar
- Por cada token ejecutan un proceso de análisis.

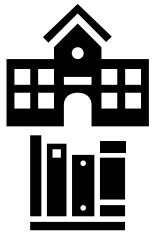
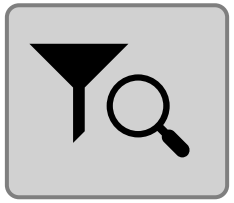
Límite en la ventana de contexto

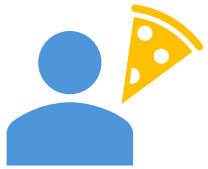
- Es posible que se supere el limite de la ventana de contexto
- En modelos pequeños solo se soportan una cantidad reducida de tokens

Recuperación de información



¿Cómo hago pizza al estilo New York en casa?

	Colecciones	**Organización**	**Búsqueda**
	Libros de muchos temas	Organizados en secciones y estantes	Bibliotecario ayuda a encontrar libros relacionados con el tema
	Documentos en base de datos	Organizados por índices	Recupera documentos por los índices

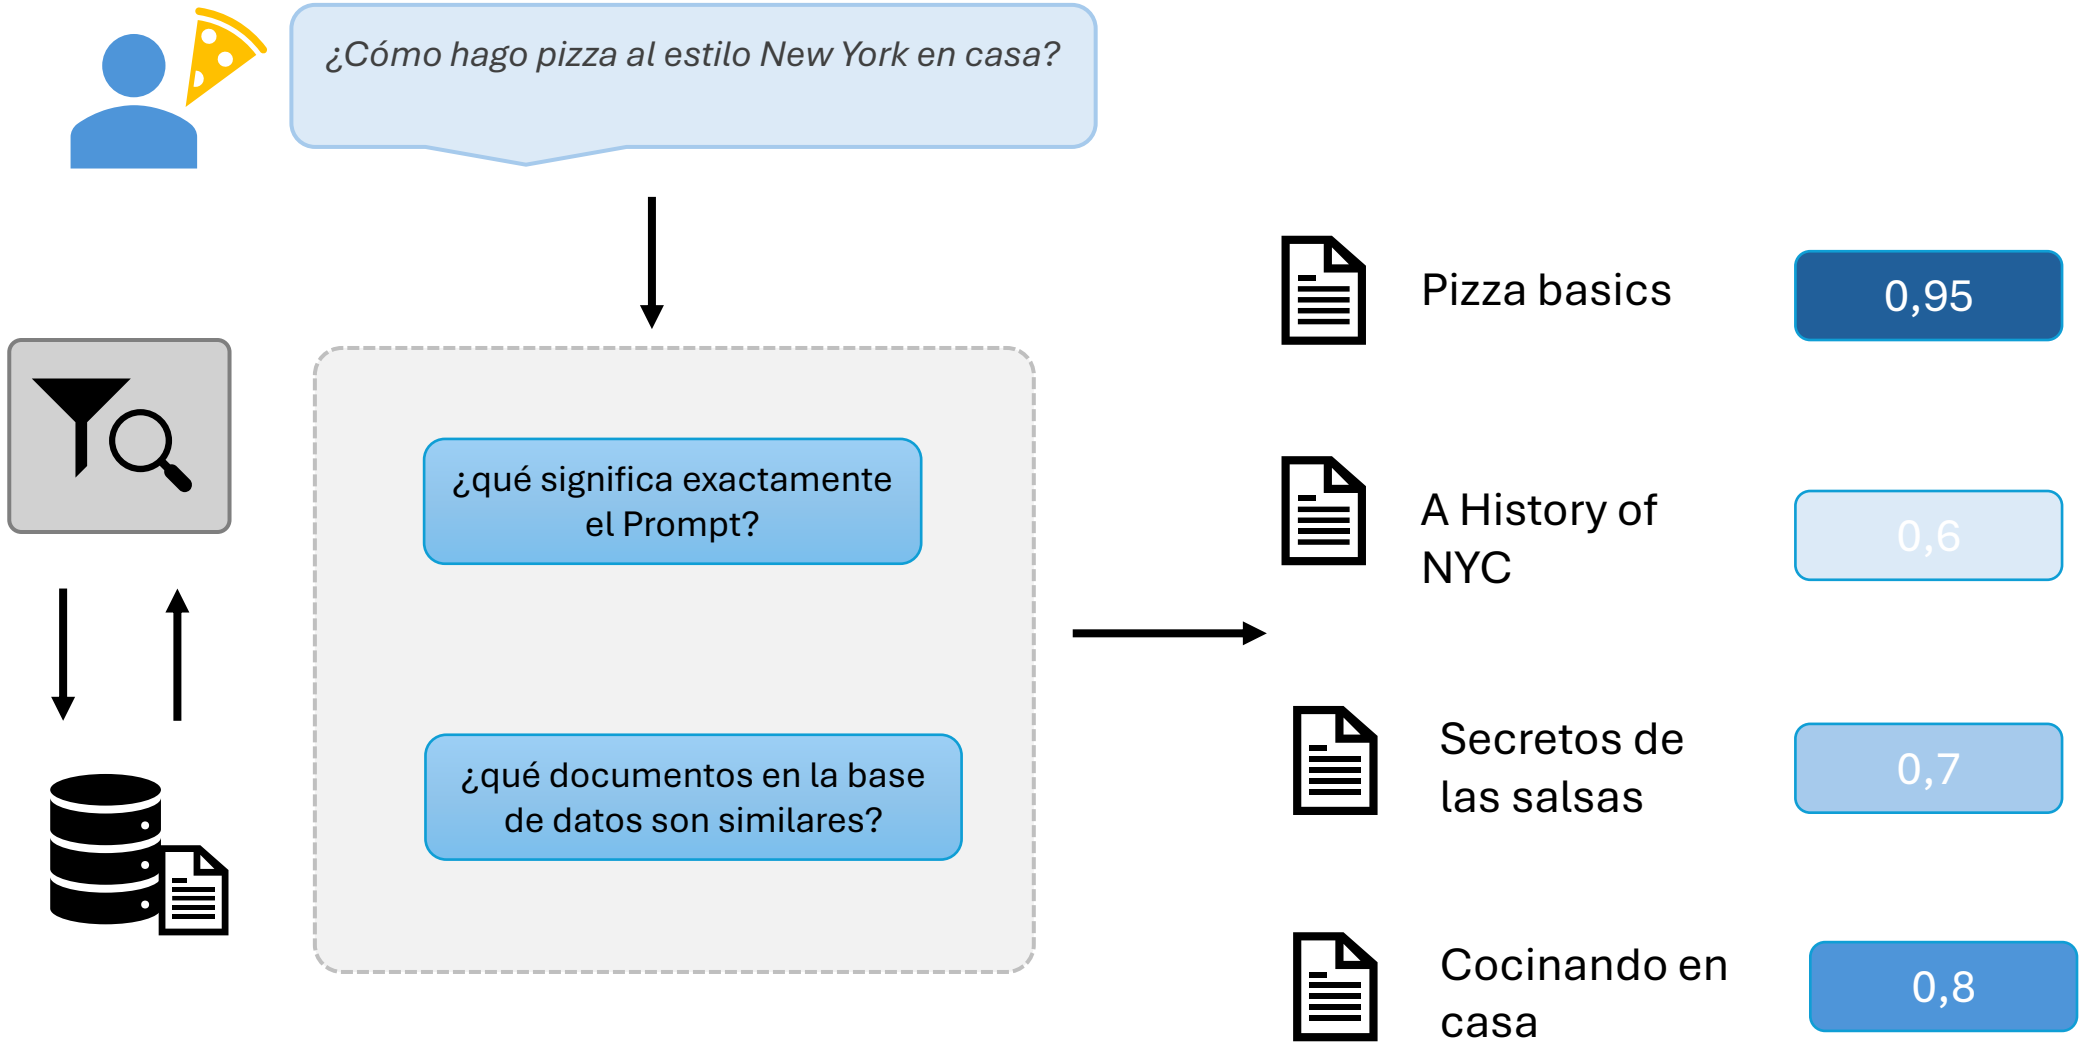


¿Cómo hago pizza al estilo New York en casa?

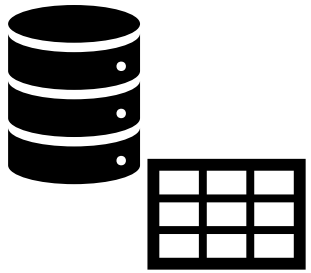


Bibliotecaria

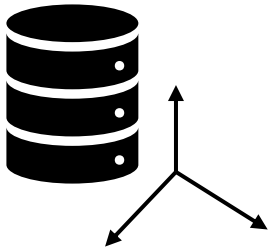
- ✓ Entiende lo que se está buscando
- ✓ Identifica el lugar donde están los libros que pueden dar respuesta
- ✓ Recomienda una selección de libros


¿Cómo hago pizza al estilo New York en casa?
¿qué significa exactamente el Prompt?
¿qué documentos en la base de datos son similares?
Pizza basics
0,95
A History of NYC
0,6
Secretos de las salsas
0,7
Cocinando en casa
0,8

Implementación



Bases de datos relacionales



Base de datos vectorial

