Asistente Experto basado en RAG

Avance 2: flujo RAG completo, evaluación con Ragas y despliegue conversacional

Autor: [Tu nombre]

Curso: [Curso / Programa]

Aplicación pública: [URL pública de la aplicación]

Repositorio: https://github.com/damoelrrr/rag-asistente

Resumen

Asistente conversacional que responde solo con la información de una base de conocimientos propia, cita el documento y fragmento de cada respuesta y se abstiene cuando la información no está en el corpus. El índice vectorial y los documentos permanecen bajo control del proyecto: los embeddings se calculan localmente y al LLM solo se envían los fragmentos recuperados para cada consulta.

1. Flujo RAG implementado

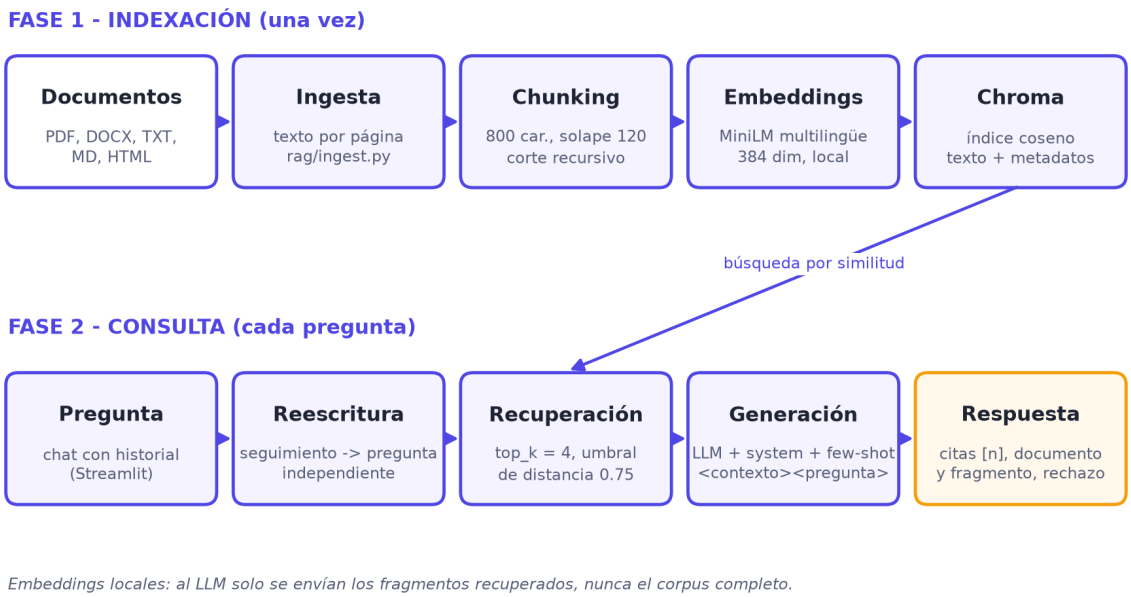


Figura 1. Pipeline de extremo a extremo: fase de indexación (arriba) y fase de consulta (abajo).

Justificación de las decisiones técnicas

Etapa	Decisión	Justificación
Selección de documentos	7 PDFs del curso «Desarrollo de aplicaciones con IA»: Introducción a RAG, survey de RAG (Gao et al., 2024), TF-IDF y búsqueda por palabras clave, BM25, ingeniería de prompts, ejecución de LLMs con Ollama y método socrático.	El asistente es un tutor del curso: el corpus cubre exactamente los temas que el estudiante consulta (recuperación, RAG, prompting, LLMs locales y la pedagogía socrática del tutor). Mezcla diapositivas breves en español con un artículo académico extenso en inglés, lo que pone a prueba un embedding multilingüe.
Ingesta	Lectores para PDF (pypdf), DOCX (python-docx), TXT/MD y HTML (BeautifulSoup).	Cubre los formatos pedidos; en PDF se conserva el número de página para citar.
Chunking	800 caracteres, solapamiento 120 (15 %), corte recursivo: párrafo, línea, frase, palabra.	Un chunk contiene una idea completa sin mezclar temas; el solape (10-20 %) evita perder ideas en los límites; respetar párrafos mantiene la coherencia.
Vectorización	paraphrase-multilingual-MiniLM-L12-v2 (384 dimensiones), local.	Multilingüe (español), liviano, sin costo y sin enviar texto a terceros; consulta y documentos usan el mismo modelo.
Base vectorial	Chroma persistente con distancia coseno. Metadatos: fuente, página, nº de fragmento.	Código abierto, embebida y persistente en disco; los metadatos permiten citar documento y fragmento.
Recuperación	Similitud coseno, top_k = 4 y descarte de fragmentos con distancia > 0.75.	El top_k equilibra cobertura y ruido; el umbral evita responder con contexto irrelevante (control de alucinaciones).
Generación	LLM vía LangChain, temperatura 0.1. System prompt con reglas, 2 ejemplos few-shot (uno de rechazo), delimitadores / y formato de salida con citas [n] y máximo 120 palabras.	Se refinó el prompt del Avance 1: delimitadores contra prompt injection, citas obligatorias y frase de rechazo exacta para detectar abstenciones.

Etapa	Decisión	Justificación
Conversación	Reescritura de la pregunta de seguimiento usando los últimos 6 mensajes.	Permite preguntas como '¿y cuál es su ventaja?', que por sí solas no sirven para buscar.

2. Ejecución de consultas sobre el RAG

Se muestran tres consultas representativas: una factual, una de síntesis que requiere varios fragmentos y una fuera del corpus. En cada captura se observa la respuesta, las citas [n] y el panel de fuentes.

2.1 Consulta factual

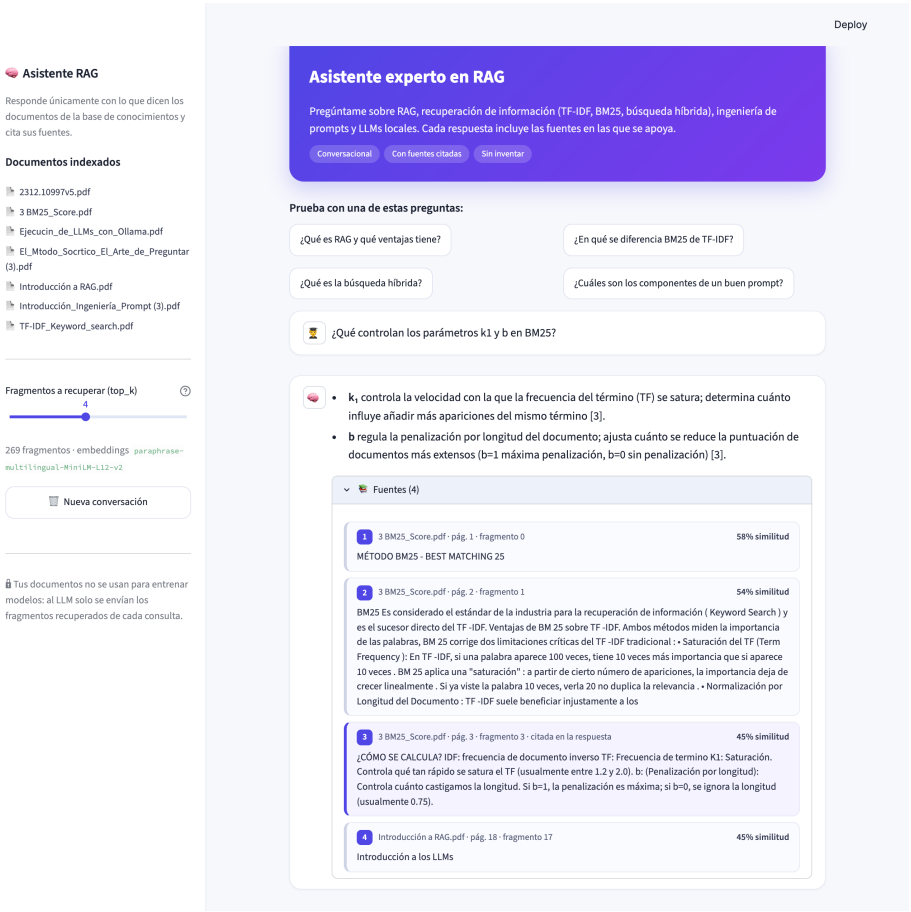


Figura 2. Consulta factual.

Análisis: Respuesta correcta y fiel: k1 controla la saturación del TF y b la penalización por longitud (b=1 máxima, b=0 nula). Cita el fragmento [3] (BM25_Score.pdf, pág. 3), que es justo la diapositiva «¿Cómo se calcula?». Omite los valores típicos (1.2-2.0 y 0.75) aunque estaban en el fragmento: el límite de 120 palabras y la pregunta, que no los pedía, llevan a una respuesta breve. Los fragmentos [1] y [4] son ruido (títulos de diapositiva).

2.2 Consulta de síntesis (varios fragmentos)

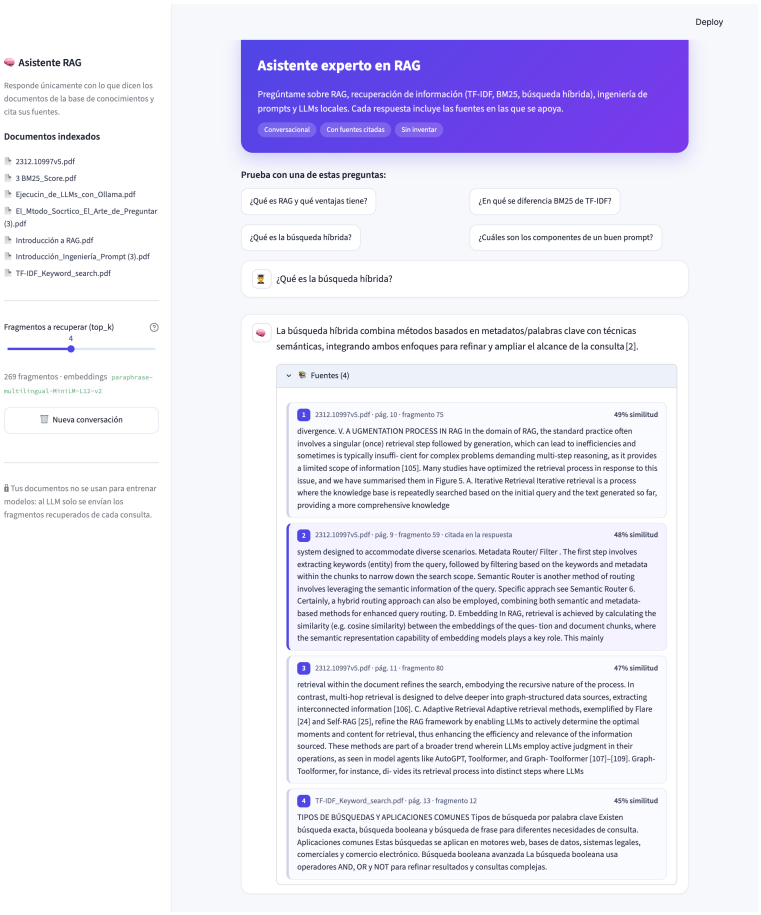


Figura 3. Consulta de síntesis (varios fragmentos).

Análisis: Respuesta incompleta, caso útil para el análisis: los 4 fragmentos recuperados vienen sobre todo del survey en inglés («hybrid routing»), y no de la diapositiva «HYBRID SEARCH» del PDF de TF-IDF, que define la combinación de keyword search, semantic search y metadata filtering. El LLM no inventa: responde solo con lo recuperado y lo cita [2]. El fallo está en la recuperación (la diapositiva es corta y mezcla títulos en inglés con texto en español), el mismo patrón que baja context_precision en Ragas. Se corregiría con búsqueda híbrida (BM25 + embeddings) o un re-ranker.

2.3 Consulta fuera del corpus

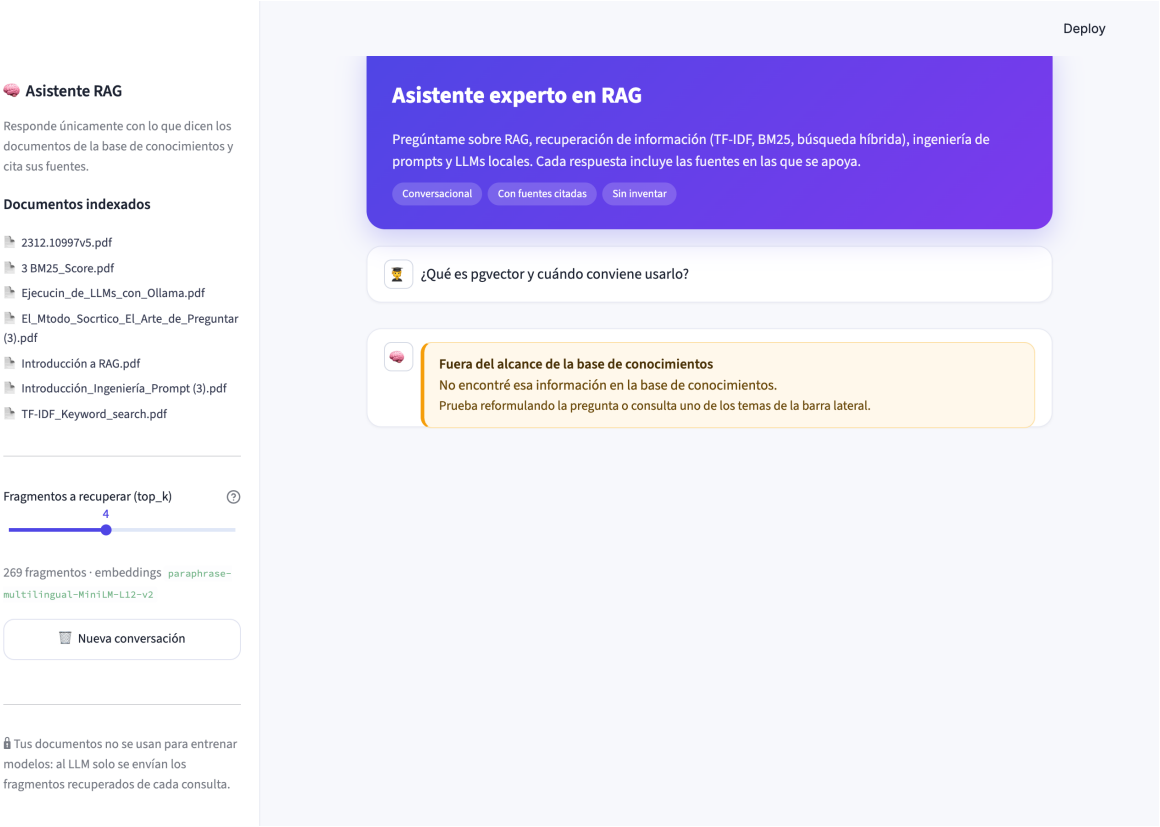


Figura 4. Consulta fuera del corpus.

Análisis: Comportamiento correcto: pgvector no aparece en ningún documento, así que el asistente responde con la frase de rechazo y la interfaz muestra el aviso «Fuera del alcance de la base de conocimientos», sin fuentes y sin inventar. En la evaluación, las 5 preguntas fuera del corpus se rechazaron en ambas configuraciones (abstención del 100 %).

3. Evaluación con Ragas

Conjunto de evaluación: 20 preguntas (eval/eval_questions.json), cada una con respuesta de referencia: 15 con respuesta en el corpus y 5 fuera de la base de conocimientos. Las cuatro métricas de Ragas se calculan sobre las 15 respondibles; las 5 restantes miden el control de alucinaciones mediante la tasa de abstención (Ragas no aplica ahí porque no existe un contexto correcto). Las métricas van de 0 a 1 (más alto es mejor).

Tabla 1. Resultados antes y después de la iteración de mejora

Métrica	Antes (base)	Después (mejora)	Cambio
faithfulness	0.59	0.79	+0.20
answer_relevancy	0.54	0.66	+0.12
context_precision	0.67	0.65	-0.02
context_recall	0.63	0.75	+0.12
Abstención fuera del corpus	1.00	1.00	+0.00

Parámetro	Antes	Después
chunk_size	1000	800
chunk_overlap	100	120
top_k	2	4

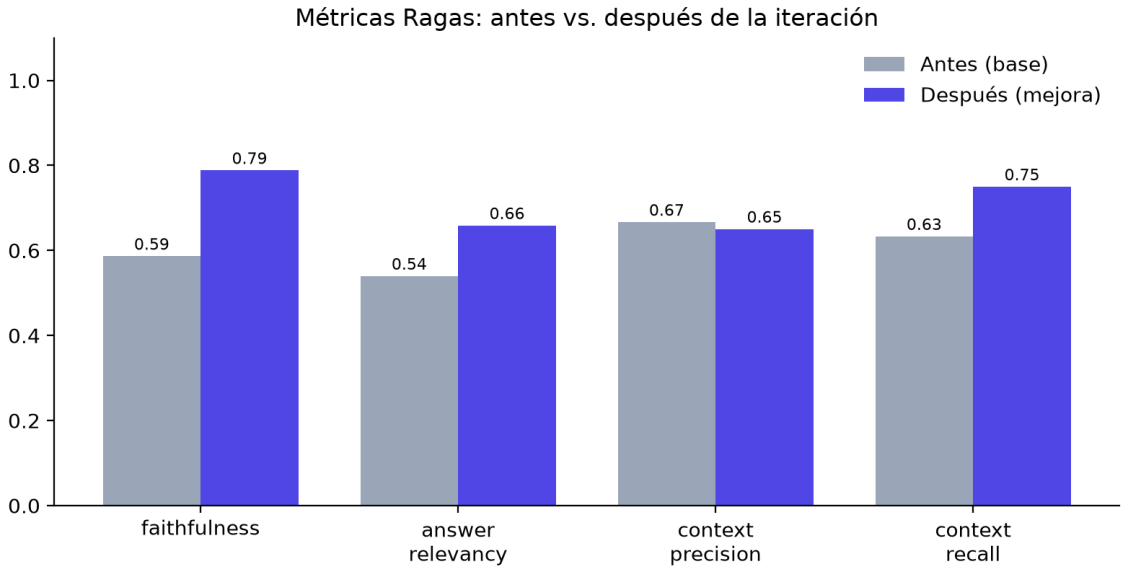


Figura 5. Comparación de métricas.

Interpretación

Con la configuración final, la métrica más baja es **context_precision** (0.65). Se atribuye principalmente a la etapa de **recuperación**: entre los fragmentos recuperados hay mucho ruido o los relevantes quedan abajo. Para mejorarla se propone reducir top_k, ajustar el umbral de distancia o añadir un re-ranker.

Lectura por pregunta (eval/results/detalle_*.csv). Las preguntas con peor puntuación comparten causa: en q03 (parámetros k1 y b) y q09 (limitaciones de TF-IDF) el fragmento con la respuesta no entra en el top_k porque lo desplazan fragmentos que solo contienen el título de una diapositiva

(«MÉTODO BM25 - BEST MATCHING 25»), así que el asistente rechaza correctamente por falta de contexto, pero answer_relevancy y context_recall caen a 0. En q11 (ventajas de RAG) se recuperan párrafos del survey en inglés en lugar de la diapositiva en español que lista las ventajas (context_precision y context_recall = 0). La generación es sólida: cuando el contexto correcto llega, faithfulness es 1.0 en casi todos los casos.

Mejoras propuestas para la recuperación: (1) búsqueda híbrida BM25 + embeddings, que favorece coincidencias exactas como «k1», «IDF» o «híbrida»; (2) unir los chunks muy cortos (títulos) con el siguiente; (3) un re-ranker cross-encoder sobre un top_k inicial mayor, para subir precisión sin perder recall.

Nota metodológica: el juez de Ragas fue openai/gpt-oss-20b (Groq, plan gratuito). En la corrida «mejora», el límite diario de tokens dejó sin puntuar 7 de las 60 evaluaciones (q13-q15). Para comparar en igualdad de condiciones, sobre las 12 preguntas puntuadas completas en ambas corridas: faithfulness 0.73 -> 0.77, answer_relevancy 0.58 -> 0.64, context_precision 0.67 -> 0.65 y context_recall 0.63 -> 0.75. La tendencia es la misma que en la tabla.

Iteración de mejora documentada

Parámetros modificados: tamaño de chunk, solapamiento y top_k. Hipótesis: chunks más pequeños y más fragmentos recuperados aumentan context_recall al aislar mejor cada idea, a costa de algo de ruido en context_precision.

Resultado: la hipótesis se confirma. context_recall sube (0.63 -> 0.75) y los rechazos indebidos de preguntas que sí tienen respuesta bajan del 33 % al 13 % (q06 y q14 pasan a responderse bien). Al tener más contexto disponible, suben también faithfulness y answer_relevancy. context_precision baja ligeramente (0.67 -> 0.65) porque 4 fragmentos traen más ruido que 2. La abstención fuera del corpus se mantiene en 100 %, así que el aumento de contexto no generó alucinaciones. Por eso la configuración desplegada es la de «mejora» (800 / 120 / top_k 4).

4. Interfaz de chat desplegada

Aplicación pública: **[URL pública de la aplicación]**
Repositorio: **https://github.com/damoelrrr/rag-asistente**

La interfaz (Streamlit) mantiene el historial del diálogo, reescribe las preguntas de seguimiento, muestra el documento y fragmento que respaldan cada respuesta y responde con un aviso claro cuando la información no está en el corpus. Las claves de API se gestionan con los Secrets de la plataforma.

4.1 Conversación con preguntas de seguimiento

PENDIENTE: pega aquí la captura
docs/screenshots/04_chat_seguimiento.png
Ej.: «¿Qué es BM25?» y luego «¿y en qué se diferencia de TF-IDF?»

Figura 6. Conversación con preguntas de seguimiento.

4.2 Caso fuera del alcance del corpus

PENDIENTE: pega aquí la captura
docs/screenshots/05_chat_fuera_corpus.png
Una pregunta ajena al corpus mostrando el aviso de 'fuera del alcance'

Figura 7. Caso fuera del alcance del corpus.

4.3 Aplicación desplegada (con la URL visible)

PENDIENTE: pega aquí la captura
docs/screenshots/06_app_desplegada.png
Captura del navegador con la URL pública en la barra de direcciones

Figura 8. Aplicación desplegada (con la URL visible).

5. Enlaces

- URL pública de la aplicación: [URL pública de la aplicación]
- Repositorio de GitHub: https://github.com/damoelrrr/rag-asistente